Estratégia Concursos

Aula 12 (Prof. Diego Carvalho e Emannuelle Gouveia)

Câmara dos Deputados - Informática e Dados

Autor:

Diego Carvalho, Renato da Costa, Equipe Informática e TI, Emannuelle Gouveia Rolim

29 de Outubro de 2025

02854629116 - Willian de Santana Angola

Índice

1) Análise de Informações - Dados, Atributos e Métricas - Teoria 3

2) Análise de Informações - Dados, Atributos e Métricas - Questões Comentadas - Multibancas 23

3) Análise de Informações - Dados, Atributos e Métricas - Lista de Questões - Multibancas 29

DADOS

Conceitos Básicos

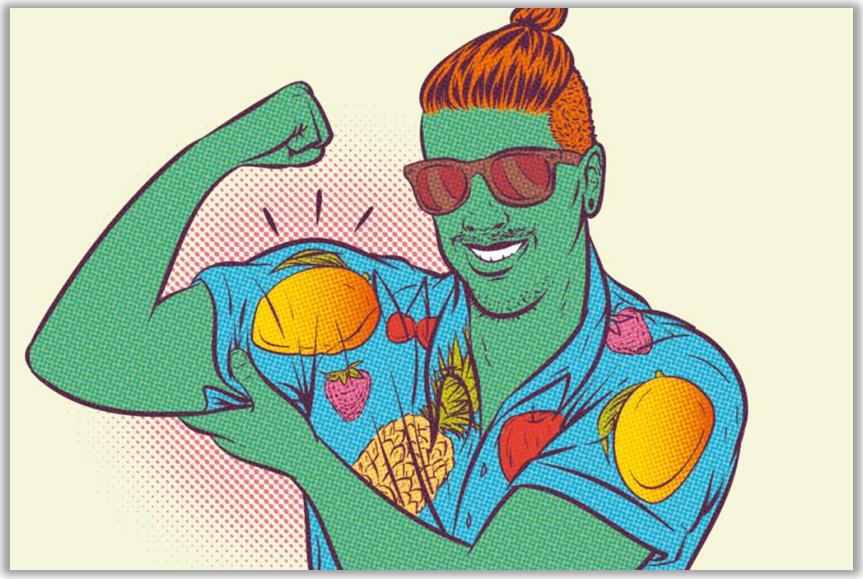
INCIDÊNCIA EM PROVA: ALTÍSSIMA

DADO
Dados são correspondências de um atributo, característica ou propriedade que, sozinho, não tem significado.
Dados são elementos brutos, sem significado, desvinculados da realidade.
Dados são simples observações sobre o estado do mundo.
Dados são um conjunto de fatos objetivos e discretos sobre eventos.
Dados são a menor partícula estruturada que compõe uma informação.

O que podemos concluir? Podemos concluir que dados são fatos ou estatísticas coletadas para servir de referência ou análise. O grande lance quando se pensa em dados é que eles não têm significado ou semântica quando vistos isoladamente – eles são brutos, simples e desvinculados de contexto/realidade. Professor, ainda não entendi! Cara... imagine que sem nenhum contexto, eu te mostro um relatório com uma tabela escrito a palavra abaixo em todas as linhas e colunas.

manga

Você consegue tirar alguma informação desse relatório? Não, você pode até inferir que se trata – por exemplo – de algum relatório sobre frutas. No entanto, você não pode afirmar com certeza! *Por quê?* Porque isso pode ser tanto um relatório de um hortifruti quanto um relatório de um camiseteria. *E aí, sem nenhum contexto, tem como saber?* Não, é impossível! *Por quê?* Porque isso é apenas um dado: **bruto, simples, objetivo e desvinculado da realidade.**



Dados são sucessões de fatos brutos, que não foram organizados, processados, relacionados, contextualizados, avaliados ou interpretados, representando apenas partes isoladas de eventos, situações ou ocorrências. Eles se constituem de unidades básicas a partir das quais informações poderão

02854629116 - Willian de Santana Angola

ser elaboradas ou obtidas. **Além disso, eles são frequentemente quantificados, facilmente estruturados, facilmente transferíveis e facilmente obtidos por máquinas.**

Quando os dados são organizados, processados, relacionados, contextualizados, avaliados ou interpretados, ele passa a ser uma informação, conforme veremos no tópico seguinte.

Agora precisamos ver a diferença entre dados estruturados e não estruturados. **Basicamente, dados estruturados são rigidamente organizados e formatados de uma maneira que seja facilmente pesquisável em bases de dados relacionais.** Professor, você falou grego agora! Calma, tudo isso será detalhado futuramente, mas – simplificando – bases de dados relacionais nada mais são que tabelas (linhas e colunas) que armazenam dados.

Logo, se eu consigo organizar um conjunto de dados em um formato que possa ser exibido em uma tabela, então esse é um conjunto de dados estruturados. *Certinho?* **Já os dados não-estruturados não possuem um formato ou uma organização predefinida, tornando muito mais difícil sua coleta, processamento e análise.** Sim, a maneira como os dados são coletados, processados e analisados depende completamente do formato em que eles estão.

Dados Estruturados

INCIDÊNCIA EM PROVA: ALTÍSSIMA

Dados estruturados são frequentemente categorizados como dados quantitativos. No seu trabalho, provavelmente você está acostumado a trabalhar com eles. Tente se lembrar! *Os dados que você trabalha podem ser organizados em linhas e colunas de bases de dados relacionais?* Se sim, você trabalha com dados estruturados! Exemplos: nomes, datas, endereços, números de cartão de crédito, tabelas do Excel, metadados (que são dados sobre dados), entre outros.

Galera, o bacana dos dados estruturados é que eles podem ser facilmente compreendidos e manipulados por linguagens de máquinas – pode-se manipular dados estruturados com relativa rapidez e essa é uma de suas maiores vantagens: **você pode ordenar, agregar, separar, juntar, inserir, atualizar, deletar e consultar dados e tabelas com facilidade.** A tabela que vimos no exemplo do tópico anterior é um exemplo de dado estruturado.

NOME	SEXO	IDADE	SALÁRIO	NATURALIDADE
ALICE	Feminino	18	R$ 8.500,00	DF
BERNARDO	Masculino	26	R$ 2.000,00	GO
CAROLINA	Feminino	30	R$ 9.500,00	TO
DAVI	Masculino	22	R$ 1.500,00	RR
EDUARDA	Feminino	32	R$ 7.500,00	SP
FELIPE	Masculino	24	R$ 3.000,00	RJ
GABRIELA	Feminino	28	R$ 6.500,00	PA
HUGO	Masculino	20	R$ 1.000,00	RS

02854629116 - Willian de Santana Angola

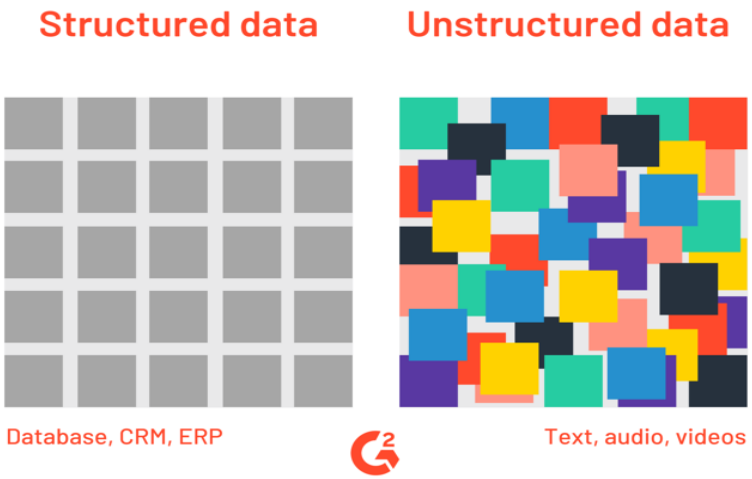
Note que, para cada linha dessa tabela, nós temos sempre as mesmas cinco colunas, com os mesmos atributos e os atributos são sempre do mesmo tipo para cada coluna (Ex: Salário é sempre um Número; Sexo é sempre uma Palavra; Naturalidade são sempre duas letras; entre outras). *Viram como é rígido?* E tem mais: eu não consigo inserir um novo atributo na tabela sem antes modificá-la (Ex: CPF) – caso eu queira inserir essa informação, devo adicionar uma coluna!

Dados Não-Estruturados

INCIDÊNCIA EM PROVA: ALTÍSSIMA

Dados não-estruturados são dados que não possuem um formato ou organização predefinida. Assim como os dados estruturados são frequentemente categorizados como dados quantitativos, os dados não-estruturados são frequentemente categorizados como qualitativos, e não podem ser processados e analisados utilizando ferramentas e métodos convencionais. Exemplos: texto, vídeo, áudio, atividades de mídias sociais, entre outros.

Dados não-estruturados são difíceis de desconstruir porque não têm um formato ou modelo predefinido, significando que não podem ser organizados em uma base de dados relacional. Mais de oitenta por cento de todos os dados gerados atualmente são considerados não-estruturados, e esse número só tende a continuar crescente com o surgimento da Internet das Coisas – tecnologia que permite que vários objetos estejam conectados à internet.



Dados Semiestruturados

INCIDÊNCIA EM PROVA: BAIXA

Dados semiestruturados é uma mistura dos dados estruturados com os dados não-estruturados. Eles não estão de acordo com a estrutura formal dos modelos de dados associados com bancos de dados relacionais ou outras formas de tabelas de dados, mas contêm tags ou outros marcadores para separar elementos semânticos e impor hierarquias de registros e campos dentro dos dados. Temos os dados junto com um esquema de representação parcialmente organizados!

Pensem em um dado que não pode ser perfeitamente encaixado em uma base de dados relacional, mas ele também não é completamente sem formato. Um exemplo clássico é o XML, que é uma linguagem que permite autodescrever um dado! Em outras palavras, ela apresenta o dado e, junto com ele, apresenta uma autodescrição. Eu sei que está difícil de imaginar, mas eu vou dar um exemplo...

02854629116 - Willian de Santana Angola

```
<xml version="1.0" encoding="UTF-8" standalone="yes" ?>

<MUSICAS xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance">
    <MUSICA>
        <NOME> THE SCRIPT FOR MY REQUIEM </NOME>
        <BANDA> BLIND GUARDIAN </BANDA>
        <ALBUM> IMAGINATIONS FROM THE OTHER SIDE </ALBUM>
    </MUSICA>
    <MUSICA>
        <NOME> STARLESS </NOME>
        <BANDA> KING CRIMSON </BANDA>
        <ALBUM> MELTDOWN </ALBUM>
    </MUSICA>
    <MUSICA>
        <NOME> CALADVWCH </NOME>
        <BANDA> DARK AVENGER </BANDA>
        <ALBUM> ALIVE IN THE DARK </ALBUM>
    </MUSICA>
</MUSICAS>
```

Esse é um exemplo de dado escrito em linguagem XML! **Notem que os dados em si são os que estão com a cor preta – todo o resto são dados que auxiliam a descrever os dados.** Apesar de, nesse exemplo, termos estruturas idênticas para cada música/banda/álbum, nada impede que haja estruturas diferentes para cada um. Por essa razão, não é possível dizer que se trata de dados completamente estruturados ou dados completamente não-estruturados. *Então, o que ele é?*



XML descreve dados semiestruturados, porque veja que é possível identificar marcações em seu código, portanto você poderia dizer que são dados estruturados. No entanto, essas tags não possuem uma ordem ou padrão específico. Você pode organizá-las da maneira que achar adequado. **Se meus dados possuem marcações identificáveis, mas sem ordem e padrão fixo, trata-se de dados semiestruturados – assim como HTML e outras linguagens de marcação!**

Por fim, é possível classificar os tipos de dados quanto à capacidade de terem suas estruturas descritas implicitamente ou explicitamente. Vejamos:

- **Dados Estruturados:** possuem uma estrutura predefinida, logo ela pode ser descrita de forma explícita – você bate o olho e identifica um padrão definido;
- **Dados Não-Estruturados:** não possuem uma estrutura predefinida, logo ela não pode ser descrita (implícita ou explicitamente) – você bate o olho e não identifica um padrão definido;
- **Dados Semiestruturados:** possuem parte de sua estrutura predefinida, logo alguns dados podem ser descritos implicitamente – você bate o olho e consegue inferir um padrão nos dados.

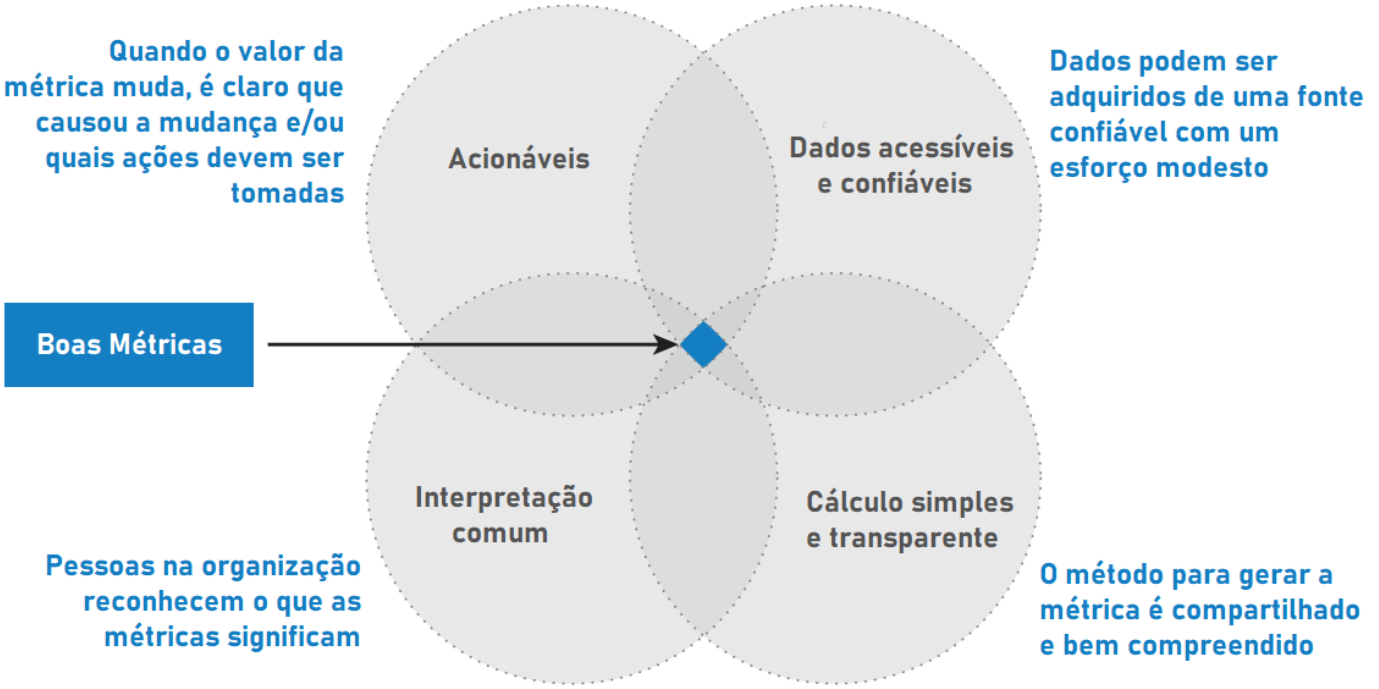
02854629116 - Willian de Santana Angola

Métricas de Dados

INCIDÊNCIA EM PROVA: BAIXA

Métricas são os valores que você usa para julgar o desempenho. Eles também são o ponto focal de qualquer produto de dados, sendo o reflexo numérico do comportamento do mundo real que sua organização deseja melhorar, evitar ou moldar. As métricas podem criar foco e alinhamento em uma organização, fornecendo clareza sobre como é a melhoria. As métricas também podem criar comportamentos contra-intuitivos ou contrários aos objetivos organizacionais.

Apesar da importância de escolher as métricas certas, é comum não pensar muito sobre o que medir. Erros comuns na escolha de métricas incluem: métricas simples demais, métricas complexas demais, grande quantidade de métricas, métricas enganosas, entre outros. Para evitar essas armadilhas muito comuns e escolher a melhor métrica possível, podemos considerar a seguinte estrutura de métricas que equilibra quatro fatores ou dimensões:



Você consegue imaginar um jogo de basquete sem aro ou uma partida de tênis sem a marcação das linhas? Na ausência de objetivos claros e de uma forma de medir o progresso, os esportes seriam desorganizados. Isso também é verdade para organizações: na ausência de métricas de sucesso organizacional claramente comunicadas, os funcionários não têm como saber se estão no caminho certo, contribuindo de maneira significativa ou apenas perdendo o controle.

Para criar uma cultura de fluência de dados, os líderes devem estabelecer as principais métricas organizacionais que orientam os esforços individuais e da organização, mas o que faz uma boa métrica?

Metas desalinhadas, comportamentos distorcidos e uma sensação equivocada de sucesso são problemas causados pelo uso de métricas ruins em uma organização. Um exemplo comum é o departamento de atendimento ao cliente que rastreia chamadas atendidas sem levar em consideração a qualidade da experiência do chamador. *E se a empresa atendeu a ligação depois de o cliente esperar por uma hora? E se a empresa atendeu a ligação, mas não resolveu o problema?*

02854629116 - Willian de Santana Angola

O primeiro passo para estabelecer o que constitui uma boa métrica é entender o que você deseja alcançar. As métricas podem servir a dois propósitos: identificar problemas e medir o desempenho. Quando o objetivo é identificar problemas e apontar áreas de ineficiência e ineficácia operacional, definir a métrica certa requer um pouco de trabalho, dado que necessita que se determine quais evidências podem ser encontradas e como exatamente elas aparecem.

Quando o objetivo é medir o desempenho, as métricas de sucesso certas se concentram em medidas que podem ser controladas e onde a melhoria na métrica é uma coisa inequivocamente boa. Depois de ter clareza sobre a finalidade para a qual você usará determinada métrica, o próximo passo é escolher uma boa métrica. Boas métricas incluem várias os fatores ou dimensões vistas na página anterior. *E o que são boas métricas?*

BOAS MÉTRICAS SÃO CRIADAS A PARTIR DE DADOS ACESSÍVEIS E CONFIÁVEIS, FÁCEIS DE COLETAR DE UMA FONTE CONFIÁVEL	**CADA MÉTRICA LEVA TEMPO E ESFORÇO PARA SER CONSTRUÍDA. ANTES DE ESCOLHER A MÉTRICA, VALE A PENA FAZER PERGUNTAS À FONTE DE DADOS: OS DADOS SÃO COLETADOS DE FORMA A CAPTURAR COM PRECISÃO A REALIDADE? OS DADOS SÃO DIFÍCEIS DE COLETAR OU ATRASADOS DE FORMA A PREJUDICAR SEU VALOR? OS CONSUMIDORES ENCONTRARÃO MOTIVOS PARA QUESTIONAR A FONTE DE DADOS? PARA QUE OS RESULTADOS TENHAM VALIDADE E PARA QUE UMA CULTURA DE ENGAJAMENTO DE DADOS SURJA EM SUA ORGANIZAÇÃO, OS PRODUTORES DE DADOS DEVEM TER ACESSO A DADOS CONFIÁVEIS.**
BOAS MÉTRICAS SÃO TRANSPARENTES E GERADAS POR CÁLCULOS COMPREENSÍVEIS	Para que as métricas identificadas por uma organização moldem a prática individual e coletiva, elas devem ser facilmente compreendidas, dando transparência de como foram desenvolvidas. Além disso, boas métricas são melhor expressas como um número ou porcentagem. Os números também devem conter pelo menos uma unidade de medida que caracterize a coisa que está sendo contada. As unidades de medida permitem que os analistas de dados expressem consistentemente os resultados de um processo de medição. O uso de duas medidas pode auxiliar nesse processo.
BOAS MÉTRICAS TÊM UMA INTERPRETAÇÃO COMUM E SÃO MEDIDAS DE FORMA CONSISTENTE	É imperativo em uma organização que todas as pessoas reconheçam o que as métricas significam e tenham certeza de que as métricas são geradas de forma consistente. Para facilitar isso, os líderes devem garantir que os processos de medição sejam claramente documentados e que os funcionários compartilhem um conjunto comum de terminologia para entender o significado das apresentações de dados.
BOAS MÉTRICAS SÃO CONTEXTUALMENTE ESPECÍFICAS E ACIONÁVEIS	Boas métricas têm significado para os membros de uma organização e sinalizam ações específicas que podem ser tomadas. Elas lançam luz sobre uma parte de baixo desempenho de uma organização, registram os resultados dos esforços de melhoria contínua ou demonstram o valor de pessoas e processos específicos dentro da organização.

EXEMPLO DE SETOR	EXEMPLO DE MÉTRICA
TRANSPORTE	Custo de transporte por quilômetro, tal como o total gasto dividido pela quantidade de km.

02854629116 - Willian de Santana Angola

DEPÓSITOS	Custo por metro quadrado, tal como o custo operacional total dividido pelo tamanho em metro quadrado.
MARKETING	Custo de aquisição de clientes, tal como o custo de vendas/marketing dividido por novos clientes em um determinado período.
E-COMMERCE	Taxa de conversão de um site, tal como a porcentagem de visitantes únicos do site que fazem uma compra.
INTERNET	Receita média por usuário (receita total dividida pelo número total de usuários).

Legal! *Agora como nós fazemos para utilizar as métricas para impulsionar a melhoria organizacional como um todo?* Vejamos...

- **Escolha algumas poucas métricas-chave em qualquer nível:** muitas organizações acabam com dezenas de métricas-chave. Na verdade, essas organizações normalmente não sabem em que focar. Líderes devem investir tempo e energia para socializar sua organização para um pequeno conjunto de métricas essenciais. O desafio é oferecer uma definição clara do que está sendo medido e demonstrar sua importância. de estabelecer um conjunto de três a cinco métricas, incorpore as métricas em reuniões e outros locais, dado que é saudável que essas métricas se tornem parte do vernáculo organizacional. Aos poucos, as pessoas vão se acostumando com as métricas e suas implicações sobre o negócio.

- **Selecione as principais métricas que se alinham com a missão e a visão:** uma transformação pode ocorrer nas organizações que aprendem no que focar. Com a consciência e a compreensão de um pequeno conjunto de métricas-chave, as pessoas começam a se perguntar quais metas estão associadas a essas métricas – é uma progressão natural. Tanto para as partes interessadas internas quanto externas, há um forte alinhamento entre missão, visão, metas e acompanhamento do progresso da organização. Os esforços de todos podem ser direcionados para essas metas mensuráveis, e as pessoas se concentrarão nos processos que podem impactar essas métricas.

- **Mostre aos funcionários que suas contribuições são essenciais:** líderes verdadeiramente excepcionais não apenas articulam metas organizacionais e identificam métricas para avaliar o progresso operacional, mas também podem ajudar os funcionários a entender como suas contribuições de trabalho são um componente essencial das metas e medidas de progresso mais amplas. As métricas devem ter uma conexão hierárquica que permita que a equipe de linha de frente veja como suas medidas se relacionam com as principais métricas de toda a organização. Na natureza, a forma segue a função e temos inúmeros exemplos de alinhamento entre atributos físicos e condições ambientais. Da mesma forma, quanto mais os indivíduos tiverem uma linha de visão clara entre suas contribuições diárias e as prioridades da organização, mais capazes (e dispostos) estarão de tomar decisões inteligentes e comprometer sua energia de maneira a sustentar o desempenho organizacional geral.

- **Referenciar métricas-chave e análise de dados ao comunicar metas:** líderes fluentes em dados lideram pelo exemplo. Da mesma forma, os líderes devem modelar a confiança na análise de dados e fazer referência às principais métricas ao comunicar metas e prioridades às partes interessadas. Para construir uma cultura fluente em dados, os líderes devem se comunicar na linguagem de suas métricas, usando dados para apoiar suas decisões sobre o progresso organizacional. Ao fazer isso, eles reforçam a importância das principais métricas selecionadas e demonstram sua alfabetização de dados em fóruns públicos, modelando assim os hábitos mentais desejados.

- **Evitando as armadilhas das métricas:** embora selecionar a métrica certa possa promover o sucesso, a métrica errada pode criar comportamentos inesperados, equivocados e contraproducentes. As métricas erradas podem criar estruturas de incentivo para comportamentos que realmente funcionam

02854629116 - Willian de Santana Angola

contra os objetivos da empresa. A maioria das empresas comete o erro de avaliar o desempenho (estabelecendo métricas de sucesso) ao longo das atividades funcionais. Isso perpetua silos disfuncionais e desconectados dentro de uma organização.

Ainda dentro desse contexto, devem-se considerar mais alguns pontos ao decidir sobre as métricas adequadas:

- **Tendências, distribuições e comparação**: um número único e solitário muitas vezes não revela uma verdadeira compreensão do desempenho de uma organização. É necessário colocar um conceito em torno do valor para permitir que as pessoas tenham uma compreensão mais completa. Ao mostrar tendências, distribuição e comparação, você melhora a compreensão da métrica para o público. A tendência mostra se a métrica se aproxima ou se afasta de uma meta. As comparações com os *benchmarks* do setor mostram como sua organização se destaca em um contexto mais amplo. Por fim, divida o valor por diferentes dimensões (por exemplo, locais, produtos e segmentos de clientes) para revelar se um fator está sustentando ou diminuindo o valor da métrica.

- **Casos extremos:** sempre haverá casos extremos, ou *outliers*, em que uma métrica pode não significar o que você pensa que significa. Vale a pena entender essas situações, mas você não deve permitir que o perfeito seja inimigo do bom. Como líder, você precisa pesar os benefícios de escolher métricas que funcionem para 90%, 95% ou 99% dos casos com os custos desses ganhos incrementais.

- **Teste de responsabilidade**: você poderia responsabilizar alguém por essa métrica sem que ela apresentasse uma dúzia de razões pelas quais isso não faz sentido? Caso contrário, talvez seja necessário reconsiderar a validade e o valor da métrica. Este exercício de pensamento simples é um bom teste do valor da métrica.

- **Autoatendimento:** tenha cuidado para não selecionar métricas simplesmente porque sabe que elas farão você parecer bom. Essas vitórias de curto prazo têm uma maneira de se transformar gradualmente em uma estratégia de longo prazo perdedora para a competitividade e o sucesso organizacional.

- **Deixar ir:** descartar uma métrica, especialmente dentro do contexto de uma organização grande, multifacetada e complexa, é uma coisa difícil de fazer. Existem alguns motivos para isso acontecer: (a) a métrica foi desenvolvida com muito esforço e alto custo; (b) Após o processo de coleta dos dados para as paradas métricas, ele só pode ser reiniciado com muito esforço e alto custo; e (c) pessoas mais altas na organização (que prestaram atenção à métrica pela última vez quando ela foi útil) podem procurá-la se algo der errado. No entanto, devemos deixar as métricas finalmente serem descartadas.

02854629116 - Willian de Santana Angola

Atributos de Dados

INCIDÊNCIA EM PROVA: BAIXA

Galera, eu escarafunchei exaustivamente a (pouca) literatura sobre fluência de dados e não encontrei absolutamente nada sobre atributos, mas achei uma página que trata do tema:

HTTPS://WWW.DIGITALFLUENCY.GUIDE/DATA/ATTRIBUTES-OF-DATA

ATRIBUTOS	DESCRIÇÃO
RELEVÂNCIA	Trata da utilidade de um conjunto de dados para os seus fins, isto é, quão relevantes são os dados para os usos pretendidos.
COBERTURA	Trata da área geográfica que o conjunto de dados descreve, isto é, se os dados se aplicam a apenas uma ou várias regiões geográficas.
AMPLITUDE	Trata de quão abrangente é a amostra do conjunto de dados, isto é, quão amplo é o conjunto de dados, se se aplica a apenas um grupo demográfico, entre outros.
PROFUNDIDADE	Trata da variedade e o número de pontos de dados diferentes no conjunto de dados, isto é, se o conjunto fornece muitos pontos de dados úteis ou apenas alguns.
CUSTO	Trata do custo de acesso e processamento dos dados, isto é, qual é o custo por unidade do conjunto de dados.
HISTÓRIA	Também chamado de comprimento ou duração, trata do alcance histórico do conjunto de dados (se houver), isto é, até quando para trás vai o conjunto de dados.
FREQUÊNCIA	Trata do intervalo de tempo entre os pontos de dados, isto é, da frequência com que os dados são atualizados.
PROCESSAMENTO	Trata da quantidade de correção de erros e rotulagem executada no conjunto de dados antes da distribuição, isto é, quão processados são os dados, se houve correções, etc.
TEMPO DE PUBLICAÇÃO	Trata do período de tempo entre a aquisição dos dados originais e a distribuição do conjunto de dados.
ESTRUTURAÇÃO	Trata do grau em que os atributos dos dados foram definidos e categorizados, isto é, quão estruturado é o conjunto de dados.
CUSTO DE PESQUISA	Trata do custo de aquisição e verificação dos dados em sua forma original, isto é, o custo de aquisição, custo de atualização, entre outros.
QUALIDADE	Trata de quão precisos são os dados originais. Se houver erros, analisa-se se eles são críticos ou apenas uma necessidade de processamento.
TENDÊNCIA	Trata dos vieses replicados nos dados por fatores humanos e/ou de máquina, isto é, se existem vieses intencionais, não intencionais ou inerentes aos dados.
DISPONIBILIDADE	Trata da facilidade de acessar o conjunto de dados, isto é, quão amplamente disponíveis estão os dados, se eles podem ser obtidos facilmente, entre outros.
ORIGINALIDADE	Trata de quão exclusivo o conjunto de dados é comparado a outros conjuntos de dados, isto é, quão original, nova, inovadora é a fonte.
TECNOLOGIA	Trata de quão avançadas são as ferramentas digitais necessárias para acessar e analisar os dados, isto é, se são necessárias tecnologias especiais para acessar ou processar os dados.
TRIAL	Trata do comprimento, a amplitude e a profundidade dos dados de pré-visualização disponíveis para avaliação.
LEGALIDADE/ ÉTICA	Trata da facilidade de acesso e uso dos dados em relação a restrições de lei, regulamentação e padrões éticos.

02854629116 - Willian de Santana Angola

PORTFOLIO/ ORTOGONALIDADE	Trata da porcentagem de casos de utilização que os dados se aplicam, isto é, se dados são úteis para diversas áreas ou apenas algumas.
ADEQUAÇÃO AO TIPO DE INVESTIMENTO	Trata de quão bem adaptados seus dados estão ao tipo de investimento que você pode fazer, isto é, se os dados são adequados para os tipos de investimento que você está considerando.
FREQUÊNCIA DE TEMPO DA ESTRATÉGIA DE INVESTIMENTO	Trata do grau em que a frequência de dados se alinha com a frequência de investimento pretendida. Se você estiver usando dados para orientar as decisões de investimento em um cronograma específico, os dados são atualizados regularmente o suficiente para serem de valor para você?
CUSTO DE ANÁLISE	Trata do custo de transformar os dados em informações úteis (diferente dos custos de processamento que precedem a análise).

Uma outra fonte traz um segundo conjunto (bem mais enxuto) de atributos de fluência de dados. Vejam na tabela a seguir:

ATRIBUTOS	DESCRIÇÃO
PRECISÃO	A precisão da análise de dados e insights.
PONTUALIDADE	A capacidade de analisar dados rapidamente e obter insights.
CONFIABILIDADE	A capacidade de produzir consistentemente resultados precisos.
RELEVÂNCIA	A capacidade de identificar dados e tendências relevantes.
ESCALABILIDADE	A capacidade de dimensionar processos de análise de dados.
CUSTO/BENEFÍCIO	A capacidade de analisar dados de maneira econômica.
QUALIDADE	A capacidade de produzir insights de dados de alta qualidade.
VALIDADE	A capacidade de validar dados e insights.
SEGURANÇA	A capacidade de proteger dados e proteger a privacidade
ROBUSTEZ	A capacidade de se adaptar às mudanças nas fontes de dados.

Transformação de Dados

INCIDÊNCIA EM PROVA: MÉDIA

Ao construir uma casa nova, antes de pensar em aspectos estéticos ou nos móveis planejados, é necessário construir uma base sólida sobre a qual serão construídas as paredes. Além disso, quanto mais difícil for o terreno em que você construirá a casa, mais tempo e esforço podem ser necessários. Se você deixar de criar uma base robusta, nada construído sobre ela resistirá ao tempo e à natureza por muito tempo.

O mesmo problema ocorre na mineração de dados e no aprendizado de máquina. Não importa o nível de sofisticação do algoritmo, se você não preparar bem sua base – ou seja, seus dados – seu algoritmo não durará muito quando testado em situações reais de dados. Mesmo os modelos mais sofisticados e avançados atingem um limite e têm desempenho inferior quando os dados não estão devidamente preparados.

Tem um ditado no meio de tecnologia da informação que diz: "Garbage In, Garbage Out". Em outras palavras, se entrarem dados ruins para serem processados por algoritmos de aprendizado de máquina, sairão dados ruins das predições dos algoritmos. E o que seria um dado ruim, Diego? São dados ausentes, anômalos, redundantes, não padronizados, entre outros. O tratamento dos dados brutos é útil para facilitar a compreensão, visualização e identificação de padrões.

Para vocês terem uma ideia, o tempo gasto no tratamento de dados pode levar cerca de 80% do tempo total que você dedica a um projeto de aprendizado de máquina. Dito isso, nas próximas páginas, nós veremos diversas técnicas de transformação (ou pré-processamento) de dados. Para cada uma das técnicas, eu vou colocar um quadrinho vermelho com um estudo de caso. Não ignorem esse quadrinho, porque geralmente é assim que as bancas cobram esse tipo de questão. Vamos lá!

Valores Ausentes

Um valor ausente costuma ser representado por um código de ausência, que pode ser um valor específico, um espaço em branco ou um símbolo (por exemplo, "?"). Um valor ausente caracteriza um valor ignorado ou que não foi observado, e, nesse sentido, a substituição de valores ausentes, também conhecida como imputação, tem como objetivo estimar os valores ausentes com base nas informações disponíveis no conjunto de dados.

A imputação de valores ausentes é uma técnica de pré-processamento que assume que a ausência de valor implica a perda de informação relevante de algum atributo. Consequentemente, o valor a ser imputado não deve somar nem subtrair informação à base, ou seja, ele não deve enviesar a base. Associado a isso está o fato de que muitos algoritmos de mineração não conseguem trabalhar com os dados na ausência de valores e, portanto, a imputação é necessária para a análise.

Além disso, o tratamento incorreto ou a eliminação de objetos com valores ausentes pode promover erros das ferramentas de análise. Para resolver o problema de valores ausentes, temos algumas opções: ignorar os objetos que possuem um ou mais valores ausentes; imputar manualmente os valores ausentes; usar uma constante global para imputar o valor ausente; utilizar a média ou moda de um atributo para imputar o valor ausente; entre outros.

No tratamento de dados ausentes (missing data), existem diferentes mecanismos que descrevem como e por que os dados não estão presentes. Vejamos:

02854629116 - Willian de Santana Angola

MECANISMO	DEFINIÇÃO	EXEMPLO	IMPLICAÇÕES PARA ANÁLISE
MCAR (Missing Completely At Random)	A ausência ocorre de forma totalmente aleatória, sem relação com variáveis observadas ou não observadas.	Questionários perdidos pelo correio, sem ligação com idade, renda ou escolaridade dos participantes.	Métodos simples, como exclusão de casos ou imputação básica, não introduzem viés. É o cenário mais "seguro".
MAR (Missing At Random)	A ausência depende de variáveis observadas, mas não da própria variável faltante.	Pessoas com baixa escolaridade não informam renda. A ausência depende da escolaridade (observada), não da renda em si.	Tratável com técnicas estatísticas como imputação múltipla ou modelagem baseada em variáveis auxiliares.
MNAR (Missing Not At Random)	A ausência depende do próprio valor ausente ou de variáveis não observadas.	Pessoas com rendas muito altas deixam de informar seu salário.	Cenário mais difícil: técnicas padrão introduzem viés. Exige coleta adicional ou modelos específicos.

Dados Inconsistentes

A consistência de um dado está relacionada à sua discrepância em relação a outros dados ou a um atributo, e tal consistência influencia na validade, na utilidade e na integridade da aplicação de mineração de dados. Esse problema geralmente ocorre de duas formas: tipos de dados inconsistentes ou mistura de formatos de dados. As inconsistências nos tipos de dados ocorrem quando os valores de uma determinada coluna não seguem o tipo de dados esperado.

Por exemplo, uma coluna que deveria conter apenas números inteiros pode ter valores de texto ou uma data pode estar representada como um texto em vez de um formato de data adequado. Isso pode afetar a análise estatística dos dados, pode causar erros em modelos de aprendizado de máquina e podem causar dificuldades na visualização dos dados. Para resolver esse problema, podemos fazer a conversão de tipos, validação de dados e tratamento de erros.

A mistura de formatos de dados ocorre quando diferentes formatos de representação são usados para o mesmo tipo de dados. Por exemplo, uma coluna de datas pode ter valores em formatos diferentes, como DD/MM/AAAA, MM-DD-AAAA, ou até mesmo AAAA.MM.DD. Isso pode causar uma confusão na integração de dados, pode causar erros de interpretação e problemas de compatibilidade.

Para resolver esse tipo de problema, podemos realizar uma padronização de formatos, utilizar bibliotecas de parsing (decomposição) e estabelecer um conjunto de regras.

Redução de Dimensionalidade

É intuitivo pensar que, quanto maior a quantidade de objetos e atributos, mais informações estão disponíveis para o algoritmo de mineração de dados. Entretanto, o aumento do número de objetos e da dimensão do espaço (número de atributos/variáveis na base) pode fazer com que os dados disponíveis se tornem esparsos e as medidas matemáticas usadas na análise tornem-se numericamente instáveis.

Além disso, uma quantidade muito grande de objetos e atributos pode tornar o processamento dos algoritmos de aprendizado de máquina muito complexo, assim como os modelos gerados. O ideal é utilizar técnicas de redução de dimensionalidade para reduzir a quantidade de atributos que descrevem os objetos. Esse tema pode ser extremamente aprofundado, mas por aqui é suficiente saber apenas isso.

02854629116 - Willian de Santana Angola

Normalização Numérica

A normalização é uma técnica geralmente aplicada como parte da preparação de dados para o aprendizado de máquina. O objetivo da normalização é mudar os valores das colunas numéricas no conjunto de dados para usar uma escala comum, sem distorcer as diferenças nos intervalos de valores nem perder informações. A normalização também é necessária para alguns algoritmos para modelar os dados corretamente.

Por exemplo: vamos supor que o conjunto de dados de entrada contenha uma coluna com valores variando de 0 a 1 e outra coluna com valores variando de 10.000 a 100.000. A grande diferença na escala dos números pode causar problemas ao tentar combinar os valores durante a modelagem. A normalização criando novos valores que mantêm a distribuição geral e as proporções nos dados de origem, mantendo os valores em uma escala aplicada em todas as colunas numéricas do modelo.

E como resolve isso? Você pode mudar todos os valores para uma escala de 0 a 1. Por exemplo: se você tiver um conjunto de dados de idades, poderá normalizá-lo para que todas as idades fiquem entre 0 e 1, subtraindo a idade mínima de cada valor e dividindo pela diferença entre as idades máxima e mínima. Vamos considerar o seguinte conjunto de dados de idade: [12, 17, 21, 29, 54, 89]. Agora utilizamos a seguinte fórmula:

$$x_i' = \frac{x_i - x_{min}}{x_{max} - x_{min}}$$

,em que x é a idade e i ∈ {1, ..., n}. Logo, vamos normalizar os valores do nosso conjunto original de dados para a escala entre 0 e 1:

$$\mathbf{IDADE}_1\text{'} = \frac{IDADE1 - IDADEmin}{IDADEmáx - IDADEmin} = \frac{12-12}{89-12} = \frac{12-12}{89-12} = \frac{0}{77} = 0{,}000$$

$$\mathbf{IDADE}_2\text{'} = \frac{IDADE2 - IDADEmin}{IDADEmáx - IDADEmin} = \frac{17-12}{89-12} = \frac{17-12}{89-12} = \frac{5}{77} = 0{,}064$$

$$\mathbf{IDADE}_3\text{'} = \frac{IDADE3 - IDADEmin}{IDADEmáx - IDADEmin} = \frac{21-12}{89-12} = \frac{21-12}{89-12} = \frac{9}{77} = 0{,}116$$

$$\mathbf{IDADE}_4\text{'} = \frac{IDADE4 - IDADEmin}{IDADEmáx - IDADEmin} = \frac{29-12}{89-12} = \frac{29-12}{89-12} = \frac{17}{77} = 0{,}220$$

$$\mathbf{IDADE}_5\text{'} = \frac{IDADE5 - IDADEmin}{IDADEmáx - IDADEmin} = \frac{54-12}{89-12} = \frac{54-12}{89-12} = \frac{42}{77} = 0{,}545$$

$$\mathbf{IDADE}_6\text{'} = \frac{IDADE6 - IDADEmin}{IDADEmáx - IDADEmin} = \frac{89-12}{89-12} = \frac{89-12}{89-12} = \frac{77}{77} = 1{,}000$$

Pronto! Agora o conjunto de dados original foi normalizado em um novo conjunto de dados contemplando valores que variam entre 0 e 1: [0, 0,064, 0,116, 0,220, 0,545, 1]. Esse tipo de normalização se chama Normalização Max-Min, mas existem outros tipos. Por fim não confundam a normalização numérica de dados com a normalização de bases de dados relacionais, que é um conceito totalmente diferente visto dentro do contexto de bancos de dados.

Existe também a normalização por padronização – também conhecida como z-score ou padronização de variáveis –, que é uma técnica de pré-processamento de dados aplicada a variáveis contínuas e tem como

02854629116 - Willian de Santana Angola

objetivo colocar essas variáveis em uma escala com média zero (0) e desvio padrão um (1). Isso significa que, após a normalização, os dados terão uma média igual a zero e um desvio padrão igual a um.

Discretização

Alguns algoritmos de mineração operam apenas com atributos categóricos e, portanto, não podem ser aplicados a dados numéricos. Nesses casos, atributos numéricos podem ser discretizados, dividindo o domínio do atributo em intervalos e ampliando a quantidade de métodos de análise disponíveis para aplicação. Além disso, a discretização reduz a quantidade de valores de um dado atributo contínuo, facilitando, em muitos casos, o processo de mineração.

A maneira mais óbvia de discretizar um certo atributo é dividindo seu domínio em um número predeterminado de intervalos iguais, o que normalmente é feito no momento da coleta dos dados. *Vamos ver um exemplo?* Imagine que tenhamos um conjunto de dados numéricos que representam o peso de um grupo de pessoas. Nesse caso, podemos dividi-los em três faixas: 50 a 75 kg, 76 a 100 kg e 101 a 150 kgs.

Anomalias (Outliers)

Também chamado de valores ruidosos, referem-se a modificações dos valores originais e que, portanto, consistem em erros de medidas ou em valores consideravelmente diferentes da maioria dos outros valores do conjunto de dados. Casos típicos percebidos quando se conhece o domínio esperado para os valores em um atributo ou a distribuição esperada para os valores de um atributo, mas, no conjunto de dados, aparecem alguns valores fora desse domínio ou dessa distribuição.

Alguns exemplos são: valores que naturalmente deveriam ser positivos, mas, no conjunto de dados, aparecem como negativos, como seria o caso de observar um valor negativo para a quantidade de vendas de um restaurante em um período de um mês; ou ainda, observar que o valor de vendas desse mesmo restaurante ultrapassa, com uma grande margem, o valor total de vendas de todos os anos anteriores.

No primeiro caso, diz-se que o valor está errado por não fazer sentido no contexto dos dados; no segundo caso, tem-se um exemplo de *outlier*, que pode representar um valor errado ou uma mudança não esperada, porém real, do comportamento dos valores de um atributo, e, nesse caso, há a necessidade de identificar qual é a explicação que se adéqua à situação. Para resolver esse problema, pode-se fazer inspeções/correções manuais ou identificação/limpeza automáticas.

Agregações

O tratamento de agregações é uma etapa fundamental no pré-processamento de dados, especialmente no contexto de mineração de dados. Esse processo envolve a combinação de múltiplas informações em uma única unidade para facilitar a análise e descobrir padrões relevantes. Existem várias técnicas de agregação, cada uma com propósitos específicos, tais como: soma, média, mediana, moda, contagem, mínimo, máximo, desvio padrão, variância, entre outros.

AGREGAÇÃO	DESCRIÇÃO
SOMA	Consiste em somar os valores de um conjunto de dados para obter um valor total. Por exemplo, somar as vendas diárias para obter o total de vendas mensais.
MÉDIA	Calcula a média aritmética dos valores de um conjunto de dados. É útil para obter um valor representativo do conjunto, como a média de vendas diárias em um mês.
MEDIANA	É o valor que divide um conjunto de dados ordenado em duas partes iguais. É usada para obter uma medida central que não seja afetada por valores atípicos (outliers).

02854629116 - Willian de Santana Angola

MODA	É o valor mais frequente em um conjunto de dados. Pode ser útil para identificar tendências ou comportamentos predominantes.
CONTAGEM	Conta o número de ocorrências de um valor ou o número total de valores em um conjunto de dados. Por exemplo, contar o número de transações em um dia.
MÍNIMO E MÁXIMO	Determinam os valores mínimo e máximo em um conjunto de dados. São úteis para entender os limites dos dados.
DESVIO PADRÃO	Mede a dispersão dos dados em relação à média. É importante para entender a variabilidade dos dados.
VARIÂNCIA	É o quadrado do desvio padrão e também mede a dispersão dos dados. É usada em análises estatísticas mais complexas.

Dentre as vantagens do tratamento de agregações, temos: redução de volume de dados – ao agregar dados, o volume total de dados é reduzido, o que pode melhorar o desempenho de sistemas de análise e armazenamento; simplicidade – dados agregados são geralmente mais simples de analisar, facilitando a identificação de padrões e tendências; eficiência – a agregação pode acelerar o processamento de consultas em bancos de dados, tornando as análises mais rápidas e eficientes.

Dados Categóricos

Dados categóricos são comuns em problemas aprendizado de máquina e, na maioria das vezes, podem ser mais desafiadores de extrair informações do que dados numéricos. Esses dados deverão ser transformados em dados numéricos para que possam ser incluídos na etapa de treinamento. Assim, uma melhor representação dos dados categóricos afeta diretamente a performance do treinamento como também introduz melhores formas de explicar sua contribuição para a predição.

A maioria dos algoritmos de aprendizado de máquina trabalha com variáveis numéricas, mas e quando temos dados categóricos? Aí temos que fazer uma conversão! Lembrando que dados categóricos podem ser ordenados (Ex: baixo, médio, alto) ou não ordenados (Ex: vermelho, azul, verde). No primeiro caso, pode-se representar por meio de uma codificação chamada *Ordinal Encoding*, em que cada valor varia de 1 até n classes (Ex: baixo = 1, médio = 2 e alto = 3).

Professor, essa atribuição de valores não pode dar problema? Pode, sim! Nesse exemplo, meu modelo pode entender que "alto" tem três vezes o peso de "baixo" – o que pode não ser verdadeiro em meu modelo de negócio. O nome desse problema é ponderação arbitrária, dado que estamos dando pesos arbitrários às classes. No caso de dados categóricos não ordenados, é mais complicado ainda e nem a solução anterior funciona.

Para resolver esse tipo de problema, o ideal é utilizar uma codificação chamada *One-Hot Enconding* ou *Dummy Encoding*. Vamos ver um exemplo rapidamente: imagine uma classificação de dados nas categorias Vermelho, Verde e Azul. Note que não existe uma ordem natural dessas categorias e atribuir valores aleatórios poderia recair no problema da ponderação arbitrária. Podemos utilizar, portanto, variáveis *dummy*. *O que seria isso, Diego?*

Variáveis *dummy* são variáveis que assumem os valores binários (0 ou 1) para representar a ausência ou presença de um determinado atributo, característica, categoria, evento ou critério.

Agora vamos criar uma tabelinha com uma coluna para cada categoria (vermelho, verde e azul). Em seguida, para cada observação do nosso conjunto de dados, vamos atribuir o valor 1 (um) – quando correspondente à categoria – e 0 (zero) – quando não correspondente à categoria. Logo, a primeira

02854629116 - Willian de Santana Angola

observação é "vermelho", logo inserimos 1 (um) na coluna "vermelho" e 0 (zero) nas outras colunas; e fazemos assim para cada uma das observações.

OBVERVAÇÕES		VERMELHO	VERDE	AZUL
VERMELHO		1	0	0
VERDE		0	1	0
AZUL		0	0	1
VERDE	ONE-HOT ENCODING	0	1	0
AZUL		0	0	1
VERMELHO		1	0	0
VERMELHO		1	0	0

Note que essa operação é bidirecional: é possível sair do valor original para o *one-hot enconding* quanto do *one-hot encoding* para o valor original. Dessa forma, não temos uma perda nem um acréscimo de informação! Existem variações dessa técnica para a codificação de dados categóricos. A vantagem dessas técnicas é permitir que o algoritmo de aprendizado de máquina entenda melhor as relações entre os dados e faça previsões mais precisas sem perda/acréscimo de dados.

Para finalizar, note que o *one-hot encoding* tem uma redundância: se eu tenho *n* categorias, eu não preciso de *n* colunas na tabela para representá-las. No caso das categorias de cores, se uma observação não é vermelha nem verde, ela é necessariamente azul; se não é vermelha nem azul, ela é necessariamente verde; e se não é verde nem azul, ela é necessariamente vermelha. Logo, para representar essas categorias, bastava n-1 colunas na tabela. Vejamos:

OBVERVAÇÕES		VERMELHO	VERDE
VERMELHO		1	0
VERDE		0	1
AZUL		0	0
VERDE	ONE-HOT ENCODING	0	1
AZUL		0	0
VERMELHO		1	0
VERMELHO		1	0

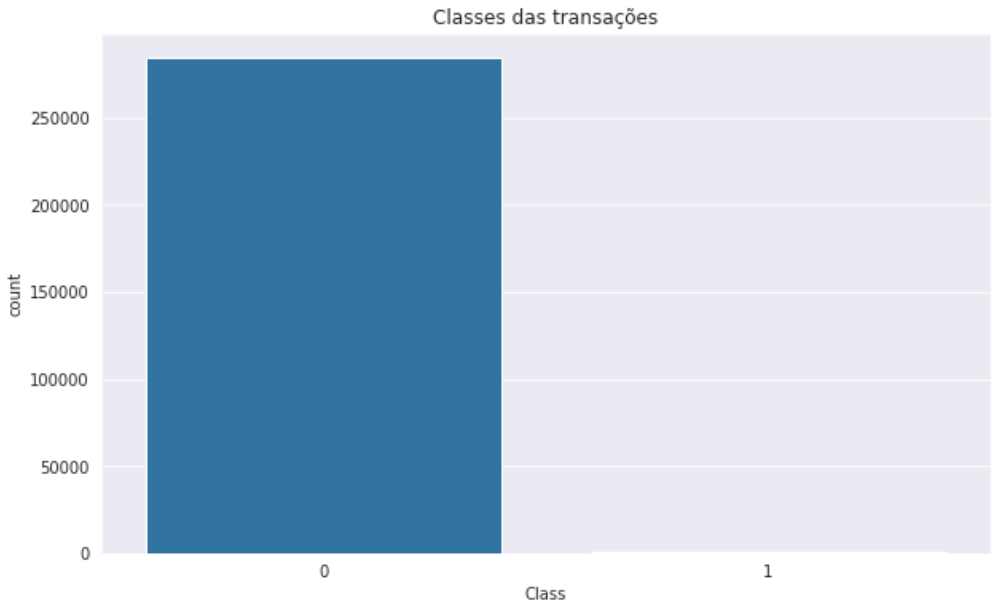
Note que, com apenas duas colunas, foi possível representar a mesma informação da tabela anterior. É bem simples: tudo que não for vermelho ou verde, será azul!

02854629116 - Willian de Santana Angola

Classes Desbalanceadas

Um problema muito comum de classificação ocorre quando existe uma desproporção nos dados, isto é, temos muito mais dados de uma classe do que de outra (pode ocorrer também para problemas com mais de duas classes). Então, quando temos um desequilíbrio de classe, o classificador de aprendizado de máquina tende a ser mais tendencioso em relação à classe majoritária, causando má classificação da classe minoritária. *Como assim, Diego?*

Imagine os dados sobre análise de fraudes em transações de cartões de crédito. *Sabe quando aparece no seu celular uma notificação sobre uma compra que você sabe que você não fez?* É aquela correria para ligar no banco e bloquear o cartão. Pois é, tem sido cada vez mais comum! Quando analisamos um conjunto de dados sobre transações de cartões de crédito, vemos basicamente duas classes: transações normais e transações fraudulentas. *E onde entra o desbalanceamento?*



Ora, eu já tive cartões bloqueados em duas oportunidades por conta de transações fraudulentas, mas é a exceção da exceção da exceção: a regra é que a imensa maioria das transações sejam normais. Vejam na imagem anterior um exemplo de um conjunto de dados de transações de uma operadora de cartão de crédito: a Classe 0 representa as transações normais e a Classe 1 representa as transações fraudulentas.

Note que nem é possível ver nada azul da Classe 1 porque é tão pouco que é quase irrelevante, mas esse gráfico representa 284.315 transações normais e 492 transações fraudulentas. Em outras palavras, temos 99,82% de transações normais e 0,17% de transações fraudulentas. *E por que isso é um problema, Diego?* Porque esse desequilíbrio pode levar a modelos tendenciosos que não são representativos da população como um todo.

Isso pode ocasionar previsões imprecisas e baixo desempenho do modelo. Além disso, pode levar a classificadores excessivamente sensíveis à classe majoritária, ignorando a classe minoritária. Galera, imagine que eu faça a pior modelagem possível de um modelo de classificação! Por pior que ele seja, se ele simplesmente "chutar" sempre que uma transação foi normal, ele acertará na maioria das vezes porque raramente uma transação é fraudulenta.

02854629116 - Willian de Santana Angola

Nesse caso, a acurácia do nosso modelo será próxima de 100%, mesmo ele tendo sido pessimamente modelado. A máquina não aprendeu nada – ela apenas foi guiada a minimizar o erro no conjunto de dados de treinamento (que tem ampla maioria de transações normais) e ignorou os padrões de transações fraudulentas. O nome disso é Paradoxo da Acurácia, em que parâmetros de um algoritmo não diferenciam a classe minoritária das demais categorias.

Ora, mas o principal objetivo de um modelo de aprendizado de máquina que trata de transações de cartão de crédito é justamente identificar padrões de transações fraudulentas a fim de impedi-las. Bacana! *E como resolve isso?* Bem, uma alternativa é conseguir mais dados de treinamento – preferencialmente da classe minoritária. Outra alternativa é alterar a métrica de desempenho: em vez de usar a acurácia.

A acurácia é uma métrica muito sensível ao acerto médio, logo não tem um bom desempenho na medição da qualidade de modelos quando o conjunto de dados tem uma desproporção muito grande entre as classes. Para resolver esse problema, podemos utilizar outras métricas de desempenho, tais como F-Score ou Curva ROC. Outra alternativa é fazer uma reamostragem e, para isso, temos duas opções...

Podemos fazer um *undersampling* majoritário (ou subamostragem), que consiste em eliminar aleatoriamente dados da classe majoritária até que ambas as classes tenham a mesma quantidade de dados. Inversamente, podemos fazer um *oversampling* minoritário (ou superamostragem), que consiste em criar novos dados baseados nos dados da classe minoritária de forma aleatória até que ambas as classes tenham a mesma quantidade de dados.

Trata-se de uma forma de garantir que os dados da classe minoritária apareçam várias vezes – é como se eu replicasse aleatoriamente dados da classe minoritária para eliminar a desproporção. É claro que essas soluções também possuem problemas: a subamostragem perde informações úteis, o que pode fazer o modelo gerar *underfitting*; já a superamostragem pode induzir o modelo a encontrar padrões de dados que não refletem a realidade da classe minoritária.

Existem outras técnicas, tais como: utilização de amostras sintéticas, atribuição de pesos diferentes às classes, utilização de algoritmos específicos para detecção de anomalias, avaliação de algoritmos menos sensíveis ao desbalanceamento (como as árvores de decisão). Enfim... existem diversas soluções e essas soluções podem ser combinadas de diversas formas para minimizar o problema do desbalanceamento (também chamado de amostras enviesadas).

Esse foi basicamente o tema de uma das questões da prova discursiva do TCU! Ele mostrava um caso em que um classificador de peças boas ou defeituosas atingiu altíssima precisão. Ocorre que o modelo basicamente que todas as peças eram boas e nenhuma peça era defeituosa – caso típico de desbalanceamento de classes. Como o modelo tinha o objetivo principal justamente de indicar peças defeituosas, ele fez um péssimo serviço!

Pedia-se também para dar exemplos de soluções, tais como *oversampling*, *undersampling*, atribuição de pesos diferentes às classes, entre outras – tudo que acabamos de estudar!

Desidentificação de Dados Sensíveis

A desidentificação de dados sensíveis é uma técnica utilizada especialmente em cenários onde a privacidade e a segurança dos dados pessoais são de suma importância. Esta técnica visa proteger a identidade dos indivíduos, removendo ou modificando informações que possam ser usadas para identificá-los diretamente ou indiretamente. Dentre as principais técnicas, temos: anonimização, pseudonimização, mascaramento, tokenização, agregação, supressão, entre outros.

02854629116 - Willian de Santana Angola

TÉCNICAS	DESCRIÇÃO
ANONIMIZAÇÃO	Eliminar informações como nome, endereço, número de telefone, e outros identificadores diretos que possam revelar a identidade de uma pessoa. Modificar dados específicos para que se tornem menos precisos, mas ainda úteis para análise.
PSEUDONIMIZAÇÃO	Substituir identificadores diretos por pseudônimos ou códigos. Esses pseudônimos não revelam a identidade real dos indivíduos sem acesso a uma tabela de correspondência segura.
MASCARAMENTO	Substituir dados sensíveis por caracteres ou símbolos, de forma que os dados reais não sejam visíveis. Por exemplo, transformar um número de cartão de crédito em "**** **** **** 1234".
TOKENIZAÇÃO	Substituir dados sensíveis por tokens únicos que podem ser mapeados de volta aos dados originais por meio de uma tabela de tokenização segura. É amplamente usado em transações financeiras.
AGREGAÇÃO	Agrupar dados de várias fontes para criar estatísticas agregadas que não podem ser atribuídas a indivíduos específicos. Por exemplo, calcular a média de uma variável para um grupo de pessoas.
SUPRESSÃO	Excluir completamente os dados sensíveis de conjuntos de dados onde sua presença não é necessária para a análise.

Dentre as vantagens dessa técnica, temos: Proteção da Privacidade – a desidentificação protege a privacidade dos indivíduos, minimizando o risco de identificação em conjuntos de dados; Conformidade com Regulamentações – ajuda a cumprir regulamentos de proteção de dados (Ex: LGPD); Facilitação da Compartilhamento de Dados – permite o compartilhamento seguro de dados entre diferentes entidades para fins de pesquisa e análise, sem comprometer a privacidade.

Viés de Seleção

O viés de seleção (também chamado de viés de amostragem) é um problema crítico que pode afetar a validade das conclusões tiradas a partir da análise dos dados. Ele ocorre quando o conjunto de dados utilizado para a análise não é representativo da população total ou quando há um processo sistemático que favorece a inclusão de certas observações sobre outras. O viés de seleção acontece quando o método de coleta ou amostragem dos dados introduz uma distorção nos resultados.

Este viés pode surgir de várias formas, como a exclusão não intencional de grupos específicos ou a inclusão excessiva de certos dados devido a conveniências na coleta. Suas causas comuns são:

- **Amostragem Não Aleatória:** quando a seleção dos dados é feita de maneira não aleatória ou baseada em conveniência, e não reflete a diversidade ou composição da população-alvo.
- **Perda de Dados:** situações em que há perda de dados de certos grupos, como quando pesquisas online excluem automaticamente indivíduos sem acesso à internet.
- **Autoseleção:** quando a participação nos dados depende da vontade dos indivíduos, como em pesquisas voluntárias, que podem atrair apenas aqueles com um interesse particular no tema.
- **Fatores Externos:** mudanças no ambiente que afetam a coleta de dados, como eventos sazonais que influenciam o comportamento de compra dos consumidores.

O viés de seleção pode ter diversos impactos:

02854629116 - Willian de Santana Angola

- **Conclusões Errôneas:** as análises baseadas em dados com viés de seleção podem levar a conclusões incorretas sobre tendências e padrões.
- **Generalização Inválida:** resultados podem não ser aplicáveis à população geral, limitando a utilidade prática das análises.
- **Modelos Prejudicados:** modelos treinados em dados enviesados podem apresentar desempenho ruim em novos dados.

QUESTÕES COMENTADAS – DIVERSAS BANCAS

1. **(CESPE / DATAPREV – 2023)** Arquivos .xml, .csv e .json são exemplos de dados estruturados.

Comentários:

Arquivos .xml (eXtensible Markup Language), .csv (Comma-Separated Values) e .json (JavaScript Object Notation) são exemplos de formatos semiestruturados. Cada um desses formatos tem características específicas que os tornam adequados para armazenar e organizar dados de maneira estruturada:

- XML é um formato flexível que usa tags para definir elementos. É comumente usado para compartilhar dados na internet e em outros ambientes de rede devido à sua capacidade de representar dados complexos e hierárquicos de forma clara.

- CSV é um formato simples que usa vírgulas (ou outro delimitador) para separar valores. Cada linha do arquivo representa uma linha de dados, e cada valor separado por vírgula representa uma coluna. Este formato é amplamente utilizado devido à sua simplicidade e compatibilidade com muitos sistemas.

- JSON é um formato leve de troca de dados, fácil de ler e escrever para humanos, e fácil de analisar e gerar por máquinas. É baseado em um subconjunto da linguagem de programação JavaScript e é muito usado em APIs da web e configurações de aplicativos devido à sua facilidade de uso em ambientes de desenvolvimento web.

Gabarito: Errado

---

2. **(CONSULPLAN / MPE-PA – 2022)** Dados são um conjunto de fatos em estado bruto que podem ser utilizados para tomadas de decisão. Os dados podem ser divididos entre estruturados e não-estruturados. Sobre os dados estruturados, assinale a afirmativa correta.

a) Mensagens de e-mail são dados estruturados.
b) Dados estruturados são organizados em linhas e colunas.
c) Dados estruturados são armazenados em arquivos no formato ".TXT".
d) Mecanismos de busca possuem dificuldade para pesquisar dados estruturados.

Comentários:

(a) Errado. Mensagens de e-mail são geralmente consideradas dados não estruturados, pois consistem principalmente de texto livre e podem conter uma variedade de formatos e anexos;

02854629116 - Willian de Santana Angola

(b) Correto. Dados estruturados são normalmente organizados em linhas e colunas, como em um banco de dados relacional. Esta estrutura permite fácil acesso, manipulação e análise dos dados;

(c) Errado. Embora seja possível armazenar dados estruturados em arquivos no formato ".txt", este não é o método predominante ou mais representativo;

(d) Errado. Mecanismos de busca, especialmente os projetados para bancos de dados, geralmente têm facilidade para pesquisar dados estruturados devido à sua organização clara e previsível.

Gabarito: Letra B

---

3. **(CONSULPLAN / MPE-PA – 2022)** Dados são um conjunto de fatos em estado bruto que podem ser utilizados para tomadas de decisão. Os dados podem ser divididos entre estruturados e não-estruturados. Sobre os dados estruturados, assinale a afirmativa correta.

   a) Mensagens de e-mail são dados estruturados.
   b) Dados estruturados são organizados em linhas e colunas.
   c) Dados estruturados são armazenados em arquivos no formato ".TXT".
   d) Mecanismos de busca possuem dificuldade para pesquisar dados estruturados.

Comentários:

(a) Errado. Mensagens de e-mail são geralmente consideradas dados não estruturados, pois consistem principalmente de texto livre e podem conter uma variedade de formatos e anexos;

(b) Correto. Dados estruturados são normalmente organizados em linhas e colunas, como em um banco de dados relacional. Esta estrutura permite fácil acesso, manipulação e análise dos dados;

(c) Errado. Embora seja possível armazenar dados estruturados em arquivos no formato ".txt", este não é o método predominante ou mais representativo;

(d) Errado. Mecanismos de busca, especialmente os projetados para bancos de dados, geralmente têm facilidade para pesquisar dados estruturados devido à sua organização clara e previsível.

Gabarito: Letra B

---

4. **(CESPE / Polícia Federal – 2021)** Os dados estruturados diferenciam-se dos dados não estruturados pela rigidez em seu formato e pelo fato de poderem ser armazenados em campos de tabelas de um banco de dados relacional.

Comentários:

02854629116 - Willian de Santana Angola

Perfeito! Dados estruturados são aqueles que são organizados e representados por meio de uma estrutura rígida e formal; já os dados não-estruturados são aqueles que não possuem uma organização rígida e formal, isto é, não seguem uma estrutura padronizada, sendo totalmente flexível e dinâmica.

Gabarito: Correto

---

5. **(CESPE / SERPRO – 2021)** Os dados não estruturados constam de bancos de dados relacionais que são eminentemente pesquisáveis tanto por meio de consultas realizadas por humanos quanto por meio daquelas realizadas por algoritmos que usam tipos de dados e nomes de campos, como alfabéticos ou numéricos, moeda ou data.

Comentários:

Na verdade, eles constam de bancos de dados não relacionais, não sendo eminentemente pesquisáveis por consultas realizadas por humanos ou por meio daquelas realizadas por algoritmos que usam tipos de dados e nomes de campos, como alfabéticos ou numéricos, moeda ou data.

Gabarito: Errado

---

6. **(CESPE/ ME – 2020)** Embora com características particulares, dados não estruturados podem ser classificados em sua totalidade, assim como os dados estruturados.

Comentários:

Galera, a questão não deixa muito claro o que quis dizer com essa classificação. De todo modo, podemos inferir que essa classificação se trata de padronização. Pois bem, dados não-estruturados não possuem uma estrutura definida e padronizada, logo não podem ser classificados em sua totalidade (como ocorre com dados estruturados).

Gabarito: Errado

---

7. **(FAURGS/ TJ-RS – 2018)** Os dados _____ são armazenados em _____. Os dados _____ misturam nomes de tipos de dados e valores de dados, mas nem todos eles precisam seguir uma estrutura predefinida fixa. Os dados _____ referem-se à informação exibida na Web, caso em que a informação sobre os tipos dos itens de dados não existe.

Assinale a alternativa que completa, correta e respectivamente, as lacunas do texto acima.

a) semiestruturados / bancos de dados tradicionais / estruturados / não estruturados
b) não estruturados / XML / semiestruturados /estruturados
c) estruturados / HTML / não estruturados / semiestruturados
d) estruturados / bancos de dados tradicionais / semiestruturados / não estruturados

02854629116 - Willian de Santana Angola

e) semiestruturados / Web / estruturados / não estruturados

Comentários:

Os dados estruturados são armazenados em bancos de dados tradicionais. Os dados semiestruturados misturam nomes de tipos de dados e valores de dados, mas nem todos eles precisam seguir uma estrutura predefinida fixa. Os dados não-estruturados referem-se à informação exibida na Web, caso em que a informação sobre os tipos dos itens de dados não existe.

Gabarito: Letra D

---

8. (CESPE / Polícia Federal – 2018)

CPF
NOME
DATA DE NASCIMENTO
NOME DO PAI
NOME DA MAE
TELEFONE
CEP
NUMERO

As informações anteriormente apresentadas correspondem aos campos de uma tabela de um banco de dados, a qual é acessada por mais de um sistema de informação e também por outras tabelas. Esses dados são utilizados para simples cadastros, desde a consulta até sua alteração, e também para prevenção à fraude, por meio de verificação dos dados da tabela e de outros dados em diferentes bases de dados ou outros meios de informação.

Considerando essas informações, julgue o item que se segue.

Os dados armazenados na referida tabela são considerados não estruturados.

Comentários:

O enunciado afirma que as informações correspondem aos campos de uma tabela de um banco de dados, logo são dados estruturados. *Por quê?* Porque possuem uma estrutura rígida, formal, homogênea e previamente formatada.

Gabarito: Errado

---

9. (CESPE / TCE-SC – 2016) Em se tratando de dados estruturados, a informação de esquema está mesclada aos valores dos dados, e cada objeto de dados pode ter atributos diferentes, que não são conhecidos com antecedência. Essa característica os diferencia de dados não estruturados.

02854629116 - Willian de Santana Angola

Comentários:

Dados mesclados com um esquema de representação parcialmente organizados são características de dados semiestruturados e, não, não estruturados.

Gabarito: Errado

---

10. **(CESPE / TCE-PA – 2016)** Em comparação aos dados não estruturados, os dados estruturados demandam mais espaço de armazenamento e um gerenciamento mais cauteloso, uma vez que constituem a maior parte dos dados corporativos.

Comentários:

A maior parte dos dados corporativos são não-estruturados, logo eles necessitam de maior espaço de armazenamento e um gerenciamento mais cauteloso.

Gabarito: Errado

---

11. **(FEPESE / SJC-SC – 2013)** Qual software, dentre os listados abaixo, permite a importação (e atualização) de dados estruturados de bancos de dados relacionais para posterior manipulação pelo aplicativo?

a) Word
b) Excel
c) Powerpoint
d) Internet Explorer
e) Outlook

Comentários:

Dados estruturados são aqueles que podem ser armazenados em... tabelas. Logo, é o MS-Excel.

Gabarito: Letra B

---

12. **(CESPE/ TRT-ES – 2013)** Os dados estruturados que descrevem e permitem encontrar, gerenciar, compreender e (ou) preservar documentos arquivísticos ao longo do tempo são conhecidos como metadados.

Comentários:

Perfeito, os dados estruturados que descrevem e permitem encontrar, gerenciar, compreender e (ou) preservar documentos arquivísticos ao longo do tempo são conhecidos como metadados.

02854629116 - Willian de Santana Angola

Gabarito: Correto

02854629116 - Willian de Santana Angola

LISTA DE QUESTÕES– DIVERSAS BANCAS

1. **(CESPE / DATAPREV – 2023)** Arquivos .xml, .csv e .json são exemplos de dados estruturados.

2. **(CONSULPLAN / MPE-PA – 2022)** Dados são um conjunto de fatos em estado bruto que podem ser utilizados para tomadas de decisão. Os dados podem ser divididos entre estruturados e não-estruturados. Sobre os dados estruturados, assinale a afirmativa correta.

   a) Mensagens de e-mail são dados estruturados.
   b) Dados estruturados são organizados em linhas e colunas.
   c) Dados estruturados são armazenados em arquivos no formato ".TXT".
   d) Mecanismos de busca possuem dificuldade para pesquisar dados estruturados.

3. **(CONSULPLAN / MPE-PA – 2022)** Dados são um conjunto de fatos em estado bruto que podem ser utilizados para tomadas de decisão. Os dados podem ser divididos entre estruturados e não-estruturados. Sobre os dados estruturados, assinale a afirmativa correta.

   a) Mensagens de e-mail são dados estruturados.
   b) Dados estruturados são organizados em linhas e colunas.
   c) Dados estruturados são armazenados em arquivos no formato ".TXT".
   d) Mecanismos de busca possuem dificuldade para pesquisar dados estruturados.

4. **(CESPE / Polícia Federal – 2021)** Os dados estruturados diferenciam-se dos dados não estruturados pela rigidez em seu formato e pelo fato de poderem ser armazenados em campos de tabelas de um banco de dados relacional.

5. **(CESPE / SERPRO – 2021)** Os dados não estruturados constam de bancos de dados relacionais que são eminentemente pesquisáveis tanto por meio de consultas realizadas por humanos quanto por meio daquelas realizadas por algoritmos que usam tipos de dados e nomes de campos, como alfabéticos ou numéricos, moeda ou data.

6. **(CESPE/ ME – 2020)** Embora com características particulares, dados não estruturados podem ser classificados em sua totalidade, assim como os dados estruturados.

7. **(FAURGS/ TJ-RS – 2018)** Os dados _____ são armazenados em _____. Os dados _____ misturam nomes de tipos de dados e valores de dados, mas nem todos eles precisam seguir uma estrutura predefinida fixa. Os dados _____ referem-se à informação exibida na Web, caso em que a informação sobre os tipos dos itens de dados não existe.

   Assinale a alternativa que completa, correta e respectivamente, as lacunas do texto acima.

   a) semiestruturados / bancos de dados tradicionais / estruturados / não estruturados

02854629116 - Willian de Santana Angola

b) não estruturados / XML / semiestruturados /estruturados
c) estruturados / HTML / não estruturados / semiestruturados
d) estruturados / bancos de dados tradicionais / semiestruturados / não estruturados
e) semiestruturados / Web / estruturados / não estruturados

8. **(CESPE / Polícia Federal – 2018)**

CPF
NOME
DATA DE NASCIMENTO
NOME DO PAI
NOME DA MAE
TELEFONE
CEP
NUMERO

As informações anteriormente apresentadas correspondem aos campos de uma tabela de um banco de dados, a qual é acessada por mais de um sistema de informação e também por outras tabelas. Esses dados são utilizados para simples cadastros, desde a consulta até sua alteração, e também para prevenção à fraude, por meio de verificação dos dados da tabela e de outros dados em diferentes bases de dados ou outros meios de informação.

Considerando essas informações, julgue o item que se segue.

Os dados armazenados na referida tabela são considerados não estruturados.

9. **(CESPE / TCE-SC – 2016)** Em se tratando de dados estruturados, a informação de esquema está mesclada aos valores dos dados, e cada objeto de dados pode ter atributos diferentes, que não são conhecidos com antecedência. Essa característica os diferencia de dados não estruturados.

10. **(CESPE / TCE-PA – 2016)** Em comparação aos dados não estruturados, os dados estruturados demandam mais espaço de armazenamento e um gerenciamento mais cauteloso, uma vez que constituem a maior parte dos dados corporativos.

11. **(FEPESE / SJC-SC – 2013)** Qual software, dentre os listados abaixo, permite a importação (e atualização) de dados estruturados de bancos de dados relacionais para posterior manipulação pelo aplicativo?

a) Word
b) Excel
c) Powerpoint
d) Internet Explorer
e) Outlook

02854629116 - Willian de Santana Angola

12. **(CESPE/ TRT-ES – 2013)** Os dados estruturados que descrevem e permitem encontrar, gerenciar, compreender e (ou) preservar documentos arquivísticos ao longo do tempo são conhecidos como metadados.

02854629116 - Willian de Santana Angola

GABARITO

1. ERRADO
2. LETRA B
3. LETRA B
4. CORRETO
5. ERRADO
6. ERRADO
7. LETRA D
8. ERRADO
9. ERRADO
10. ERRADO
11. LETRA B
12. CORRETO

ESSA LEI TODO MUNDO CONHECE:
PIRATARIA É CRIME.

Mas é sempre bom revisar o porquê e como você pode ser prejudicado com essa prática.

1. 

Professor investe seu tempo para elaborar os cursos e o site os coloca à venda.

2. 

Pirata divulga ilicitamente (grupos de rateio), utilizando-se do anonimato, nomes falsos ou laranjas (geralmente o pirata se anuncia como formador de "grupos solidários" de rateio que não visam lucro).

3. 

Pirata cria alunos fake praticando falsidade ideológica, comprando cursos do site em nome de pessoas aleatórias (usando nome, CPF, endereço e telefone de terceiros sem autorização).

4. 

Pirata compra, muitas vezes, clonando cartões de crédito (por vezes o sistema anti-fraude não consegue identificar o golpe a tempo).

5. 

Pirata fere os Termos de Uso, adultera as aulas e retira a identificação dos arquivos PDF (justamente porque a atividade é ilegal e ele não quer que seus fakes sejam identificados).

6. 

Pirata revende as aulas protegidas por direitos autorais, praticando concorrência desleal e em flagrante desrespeito à Lei de Direitos Autorais (Lei 9.610/98).

7. 

Concurseiro(a) desinformado participa de rateio, achando que nada disso está acontecendo e esperando se tornar servidor público para exigir o cumprimento das leis.

8. 

O professor que elaborou o curso não ganha nada, o site não recebe nada, e a pessoa que praticou todos os ilícitos anteriores (pirata) fica com o lucro.



Deixando de lado esse mar de sujeira, aproveitamos para agradecer a todos que adquirem os cursos honestamente e permitem que o site continue existindo.